



Assistance par IA pour les entretiens de recrutement

Présentée par :

Wiem BEN ROMDHANE

Président :

M^{me} Imen BOUDALI

Encadrant Entreprise :

Mr Ali MANSOUR

Rapporteur :

M^{me} Linda MARRAKCHI

Encadrant ENIT :

M^{me} Soumaya MEHERZI

Année académique : 2024-2025

Plan

01 Introduction et Contexte

02 Problématique et objectifs du projet

03 Modèles existants

04 Solution proposée et Architecture générale

05 Implémentation et Résultats

06 Développement de l'interface web

07 Conclusion & Perspectives

01 Introduction et Contexte

Présentation de l'entreprise d'accueil : I-LEAD CONSULTING



- Fondation : 2015 par trois experts en ingénierie
- Domaines clés : Business Intelligence, Études & Développement, MOA, DevOps, Tests & Validation.
- Mission : accompagner les entreprises avec des solutions adaptées et de haute qualité.

01 Introduction et Contexte

Contexte du projet

- Importance des entretiens dans le recrutement
- Difficulté d'évaluer les émotions
- Opportunité offerte par l'IA multimodale

02 Problématique et objectifs du projet



Comment automatiser cette analyse et l'intégrer dans une interface de TalentCube ?

03 Problématique et objectifs du projet



- Détection automatique des émotions multimodales (vidéo + audio)
- Génération de rapports psychologiques synthétiques
- Intégration dans une interface web simple d'utilisation

04 Modèles existants



- Modèle d'apprentissage pour la vision
- Modèle d'apprentissage pour l'audio
- Modèle d'apprentissage pour le NLP

Modèle d'apprentissage pour la vision

Modèle	Type	Points forts	Limites
I3D (Inflated 3D ConvNet)	CNN 3D	Exploite info spatio-temporelle, pré-entraîné sur Kinetics	Coût calcul élevé
ResNet	CNN 2D (résiduel)	Simplicité, rapidité, connexions résiduelles, bon compromis précision/complexité	Plus coûteux en calcul avec la profondeur
DenseNet	CNN 2D (connectivité dense)	Réutilisation des features, efficace paramétriquement	Plus complexe que ResNet
EfficientNet	CNN 2D (compound scaling)	Excellent rapport précision/FLOPs	Mise en œuvre plus lourde
ViT (Vision Transformer)	Transformer pur	Capture des relations globales	Besoin de très grands datasets, coûteux


Modèle d'apprentissage pour l'audio


Modèle	Type	Points forts	Limites
CNN 1D	Convolutions sur signal brut	Extraction locale rapide, architecture simple	Peu de contexte global
RNN / LSTM / GRU	Réseaux récurrents	Capture des dépendances temporelles	Entraînement lent, gradients instables
vq-wav2vec / wav2vec	Auto-supervisé	Bon sur phonèmes, pré-entraînement simple	Performances limitées
Wav2Vec 2.0	CNN + Transformer + quantification	Représentations riches, apprentissage masqué, SOTA sur PER/WER	Plus lourd mais très efficace

Modèle d'apprentissage pour le NLP


Modèle	Type	Points forts	Limites
Méthodes classiques (SVM, Naive Bayes)	ML traditionnel	Simple, rapides sur petits jeux de données	Peu performants pour dépendances longues
RNN	Réseaux récurrents	Gèrent séquences, mémoire court terme	Difficultés sur dépendances longues, entraînement lent
Transformers (BERT, GPT...)	Self-attention	Capturent dépendances globales, parallélisation	Modèles lourds, besoin de gros corpus
Mistral 7B Instruct	LLM basé sur Transformer	Performant, quantifié (SWA, GQA), multilingue, efficace pour instructions	Moins puissant que des modèles propriétaires plus gros

05 Solution proposée et Architecture générale






Architecture de ResNet18



Architecture de Wav2vec 2.0




Architecture de Mistral 7B


- Basé sur le transformer
- Les caractéristiques de Mistral :
 - Sliding Window Attention (SWA)
 - Grouped-Query Attention (GQA)
 - Byte-fallback BPE

Architecture du transformer


- Basé sur l'attention
- Proposé la première fois en 2017 dans le contexte NLP
- Meilleures performances par rapport aux modèles classiques



06 Implémentation et Résultats




Choix du modèle de détection d'émotion multimodale entre "fusion précoce" et "fusion tardive"



Fusion précoce des deux modalités

Choix du modèle de détection d'émotion multimodale entre "fusion précoce" et "fusion tardive"




Fusion tardive des deux modalités

Choix du modèle de détection d'émotion multimodale entre "fusion précoce" et "fusion tardive"

Les entraînements sont faits avec:

- un dataset : 1200 clips équilibré sur les six classes d'émotions
- Dataset split: 70/15/15 (train/val/test)
- Batch size = 24
- Nombre d'epochs = 5
- Taux d'apprentissage = 1e-4

Fusion	Précision test	Précision test Top-3	Temps/epoch
Précoce	91.53%	97.61%	2 min 25 s
Tardive	91.97%	98.13%	2 min 30 s




- Fusion tardive:
- Précision supérieure
 - Richesse de sortie

Entraînement du modèle choisi


L'optimisation des hyperparamètres se fait avec optuna

➔ Précision test de **92.38%** top 1 et **99.01%** top 3.



Fusion tardive des deux modalités

Pipeline complet de la génération du rapport



Prompt

```
prompt = f"""[INST] <<SYS>>
    Tu es un assistant qui génère des phrases simples à
    partir d'une transcription et d'une analyse émotionnelle.
    Ton objectif est de produire une analyse psychologique
    de 3 à 5 lignes qui commence par "il est {{émotion}}
    lorsqu'il ..."
    Fais attention à respecter le sens des phrases et
    répondre toujours uniquement en français.
    Voici les données :
    - Plage: {start_min:02d}:{start_sec:02d}-{end_min:02d}:{end_sec:02d}
    - Emotion: {dominant_emotion}
    - Transcription: {result['transcription']}
    <</SYS>>[/INST]"""
```

Résultats: un exemple du rapport sur un segment

```
859 [21:47-22:13]
860 Emotion dominante: Disgust
861 Distribution des probabilités (image):
862 - Angry: 3.24%
863 - Disgust: 81.30%
864 - Fear: 0.14%
865 - Happy: 13.16%
866 - Sad: 0.36%
867 - Neutral: 1.81%
868 Distribution des probabilités (audio):
869 - Angry: 16.19%
870 - Disgust: 25.04%
871 - Fear: 15.46%
872 - Happy: 14.62%
873 - Sad: 12.88%
874 - Neutral: 15.80%
875
876 Transcription: " que voilà, il y a 50 ans, après, j'ai fait une vente ou deux dans ma vie, donc je suis capable
877 effectivement d'en parler mais je respecte tout à fait la vie d'un corps-momme indéputant, en même un agir, on
878 fait, il a droit d'avoir une bonne idée, et un ensemble de tout, c'est un ce nourrit des autres, on can dire, tout à fait."
879
880 Analyse psychologique:
881 Il est disgusté lorsqu'il parle de la vente qu'il a effectué il y a 50 ans, car il respecte complètement la
882 vie d'un corps-momme indépendant. On peut dire que tout cela est nourrit des autres, mais il a droit d'avoir une bonne idée en agissant.
883 -----
```

- Incohérence modèle (dégoût) vs. perception humaine (neutre)
- Modalité image domine sur celle audio qui est proche d'un classifieur aléatoire
- Whisper : des fautes ("indéputant" → "débutant") => dégradation du prompt / baisse de la qualité du rapport généré.

Limitations

- Écart significatif entre les données d'entraînement et d'évaluation.
 - Entraînement (CREMA-D) : Séquences courtes (3s), émotions explicites et exagérées.
 - Notre contexte (Entretien) : Séquences longues (8-40s), émotions implicites et subtiles.
- Les limites de la version libre de Whisper :
 - Transcription imparfaite (fautes, mots manquants).
 - Difficulté avec le débit de parole naturel et spontané.

07 Développement de l'interface web



Objectif :

solution IA accessible aux recruteurs

Rôle :

téléversement, analyse, génération de rapports

But:

application web intuitive et ergonomique

 TalentCube 

wiem

Tableau de bord

Vue d'ensemble

Résultats

Candidats

Création de question

Gestion des questions

Analyse des candidatures

Analyse des entretiens

Paramètres

WB

wiem ben romdhane

wiembenromdhane912@gmail.com

Se déconnecter

Changer votre abonnement

Tableau de bord



Analyse des émotions

 **Uploader la vidéo d'entretien**

Type de fichier (MP4/AVI, etc...)

Taille limite 1Go


Drag and drop a video here or click to upload

Envoyer l'analyse

Activer Windows
Accédez aux paramètres pour activer Windows.

Analyse des émotions

 **Uploader la vidéo d'entretien**

Type de fichier (MP4/AVI, etc...)

Taille limite 1Go


Drag and drop a video here or click to upload

 test4.mp4 a été uploadée avec succès

Envoyer l'analyse

Analyse des émotions

Uploader la vidéo d'entretien

Type de fichier (MP4)

Taille limite 1Go

✓

test4.mp4 a été uploadée avec succès

Envoyer l'analyse

Envoyer le rapport

Adresse mail *

Envoyer

TalentCube

Dans quelques minutes, vous allez recevoir vos résultats

localhost:4200 indique

✓ Analyse effectuée et rapport envoyé avec succès.

OK

08 Conclusion et perspectives

- Bilan : IA multimodale (vidéo + audio) + génération de rapports + interface web.
- Apports : outil d'aide au recrutement, objectif et complet.
- Perspectives : amélioration du dataset, ajout de nouveaux signaux.



MERCI DE VOTRE
ATTENTION